

# Основы анализа данных и ML

Курс для «Дагестанского государственного технического университета»

Махачкала, 2026

# Зачем ещё один курс по ML?

и для чего он вам

## Базовое понимание

Разберёмся, что такое Data Science, AI, ML; какие задачи они решают, и зачем это изучать

## Практические навыки

Научитесь работать с реальными данными: анализировать, чистить, визуализировать и готовить для моделей

## Реальный проект


Разработаем StreamLit-приложение с разработанными моделями — готовый проект для GitHub

## Карьерная траектория

Определите, нравится ли вам эта область, прежде чем идти дальше и строить карьеру

# Что мы изучим на курсе

Курс охватывает первые 3 этапа:



### 1. Работа с данными

Постановка задачи, типы данных, анализ и обработка данных (пропуски, выбросы)

### 2. Базовые модели

Линейная и логистическая регрессия, интерпретация коэффициентов


### 3. Оценка качества

Train/validation/test, метрики (accuracy, precision, recall, F1)



+ разработаем Streamlit-приложение для GitHub-портфолио

# Структура курса: 5 занятий



# Критерии зачёта

Основной критерий – формула оценки

$$0.4 * \text{степик} + 0.6 * \text{проект} + 0.1 * \text{беседа}$$

$$* \text{курс на Степик} = \frac{\% \text{ пройденного материала}}{100} * 10$$

Балл для зачета

для получения зачета нужно получить  $\geq 6$  баллов

Экзамен (ака “Беседа”)

- не понижает оценку, напротив - дает доп балл
- список вопросов заранее известен
- нужно ответить на 3 вопроса
- по желанию провести мок-собеседование (необходимо уведомить заранее)

24.10

31.10

\*возможные даты


формат дз: курс на Stepik

+

финальный проект:

- Создать **Streamlit-приложение** для предсказания цены на квартиру в Дагестане
- Анализ данных → модель → деплой
- Полноценный проект в GitHub для портфолио

# Ссылки



Групповой чат: <https://t.me/+g2Zg0lQG2UglM2Y6>

Курс на Stepik: <https://stepik.org/course/297193/info>

Github курса: [https://github.com/abdullaevagulya/dstu\\_ml\\_base](https://github.com/abdullaevagulya/dstu_ml_base)


Ссылка на записи: <https://www.youtube.com/playlist?list=PLQdUxaYsJpn4>

# Вопросы



# DS, AI, ML, DL – как не запутаться?

- **AI** — artificial intelligence  
искусственный интеллект
- **ML** — machine learning  
машинное обучение
- **DL** — deep learning  
глубинное/глубокое обучение
- **DS** — data science  
наука о данных



# Искусственный интеллект


- системы, которые выполняют задачи, требующие «интеллектуального» поведения
- включает ML, DL, LLM, а также более ранние подходы — **системы на правилах**
- первые AI-системы часто работали по логике «если → то», заданной человеком

## Пример:

Если идёт дождь → улица мокрая

Если улица мокрая → возможно, шёл дождь

Правила задаются заранее: система не обучается на данных, а делает вывод по заложенной логике




# Машинное обучение

- подмножество AI: алгоритмы учатся закономерностям в данных
- модель получает примеры (данные) и строит прогноз для новых объектов
- типичные задачи: классификация, регрессия, рекомендации *и т.д.*

## Пример:

- 1) подаем в модель площадь, район, этаж → обучаем →  
модель предсказывает цену квартиры
- 2) подаем в модель текст письма → обучаем →  
модель определяет спам или не спам




DL

# Глубокое обучение

- подмножество ML: модели на основе многослойных нейронных сетей
- особенно полезно для текста, изображений, аудио и видео
- современные LLM и многие системы компьютерного зрения относятся к DL

### Пример:

- 1) подаем изображения → модель определяет, что на нём изображена кошка
- 2) современные чат-боты




DS

# Data Science

- **цель** – получить полезные выводы из данных и принять на их основе решение
- работа с данными: сбор, очистка, анализ, визуализация и интерпретация
- использует статистику, теорию вероятностей *и т.д.*

## Пример:

- 1) Продажи снизились на 15% → найти причину по данным
- 2) Сравнить регионы по зарплатами, построить графики и выделить ключевые факторы, влияющие на оклад



# Data Science vs Machine Learning vs AI

AI —  
Искусственный  
интеллект

Широкая область:  
любая система,  
которая имитирует  
интеллект

Machine Learning

Подмножество AI —  
системы, которые  
**учатся на данных**

DL

Подмножество ML —  
Нейронные сети,  
современные LLM

Data Science

Дисциплина, которая  
использует ML и  
статистику для  
извлечения знаний из  
данных

Транспорт → Автомобили → Гоночные автомобили

# Machine Learning

наш фокус

— это часть AI, в которой мы уже не прописываем все правила вручную. Вместо этого даём алгоритму данные, и он пытается самостоятельно найти в них закономерности, после чего делает прогнозы на основе выявленных закономерностей

*или*

— набор всех задач, в которых компьютер может делать прогноз на основе данных

какие задачи бывают?

# Как устроено обучение?

```
graph TD; A[Контролируемое] --> B[Неконтролируемое]; B --> C[Обучение с подкреплением];
```

Контролируемое

Неконтролируемое

Обучение  
с подкреплением

# Supervised Learning

**Контролируемое** обучение — это процесс обучения модели на **размеченных** данных  
(**можем** использовать значение целевого признака для обучения)

каждый столбец – **признак**  
или **feature** [фича] (от англ. признак)

| Кол-во<br>комнат | Площадь, м <sup>2</sup> | Цена, млн Р |
|------------------|-------------------------|-------------|
| 3                | 109                     | 11.3        |
| 2                | 72                      | 6.7         |
| 1                | 52                      | 4.5         |

признак, который необходимо  
предсказать называется **целевым**

или **target** [таргет] (от англ. цель)  
или **меткой**

каждая строка – **объект**  
или **наблюдение**

# Тип задачи — регрессия

Регрессия — задача, в которой модель предсказывает **числовое значение**

пример: **предсказываем цену квартиры**

известны характеристики продаваемых квартир → учимся на них

| Кол-во комнат | Площадь, м² | Цена, млн ₽ |
|---------------|-------------|-------------|
| 3             | 109         | 11.3        |
| 2             | 72          | 6.7         |
| 1             | 52          | 4.5         |

**Наш вопрос:** какая будет цена у 2х-комнатной квартиры площадью 65 м²?



Модель отвечает на вопрос **числом**,  
**выдает цену**

# Тип задачи — классификация

Классификация — задача, в которой модель предсказывает **категорию из целевого признака (класса)**

пример: **определяем, является ли письмо спамом**

учимся на письмах, для которых уже известен правильный класс

| Размер письма, кб | Есть ссылка | Класс (target) |
|-------------------|-------------|----------------|
| 200               | да          | СПАМ           |
| 32                | нет         | НЕ СПАМ        |
| 187               | да          | СПАМ           |

Наш вопрос: данное письмо – спам?



Модель отвечает на вопрос **классом**:

СПАМ

НЕ СПАМ

на выходе — категория / класс  
*классов может быть 2 и больше*


# Какие у вас есть идеи?

классификация

регрессия



VISAGEHALL



# Какие у вас есть идеи?

классификация

регрессия

длительность  
строительства

оценка риска сделки:  
низкий/высокий риск




время доставки



классификация  
отзывов клиента

VISAGEHALL

прогноз затрат на  
производство



спрос на товар



прогноз объема  
заказов



отток постоянного заказчика /  
или он останется

# Как устроено обучение?

Контролируемое


Неконтролируемое

Обучение  
с подкреплением

# Unsupervised Learning


**Неконтролируемое** обучение — это процесс обучения на **неразмеченных** данных.  
(**не можем** использовать значение целевого признака для обучения)

| id письма | Размер | Получатели |
|-----------|--------|------------|
| 1         | 8      | 1          |
| 2         | 12     | 1          |
| 3         | 43     | 1          |
| 4         | 10     | 2          |
| 5         | 40     | 2          |
| 6         | 25     | 5          |
| 7         | 23     | 6          |
| 8         | 28     | 6          |
| 9         | 26     | 7          |




# Reinforcement Learning, RL

**Обучение с подкреплением** — это тип обучения, при котором программа или робот (агент) **не получает готовых** правильных ответов, а **учится выполнять задачу** методом проб и ошибок, взаимодействуя со средой и получая награду или штраф за свои действия.



Правила:  
Дойти до сундука **+100 очков**  
Дойти до дракона/горы **-50 очков**



# Словарь

|                          |                                                                                                 |
|--------------------------|-------------------------------------------------------------------------------------------------|
| Объект / наблюдение      | Одна строка в датасете. Например, одна квартира                                                 |
| Признак / feature        | Характеристика объекта. Например, площадь, этаж, число комнат                                   |
| Целевой признак / target | Признак, который модель должна предсказать                                                      |
| Регрессия                | Задача ML, в которой целевой признак числовой. Например, цена квартиры                          |
| Классификация            | Задача ML, в которой целевой признак категориальный. Например, спам / не спам                   |
| Бинарная классификация   | Классификация с двумя возможными классами, например 0/1 или да/нет                              |
| Числовые данные          | Данные, значения которых являются числами и имеют количественный смысл                          |
| Категориальные данные    | Данные, представляющие отдельные категории или классы, например- цвет (белый/черный) или да/нет |
| Кластер                  | Группа похожих объектов, найденная алгоритмом без заранее заданных меток                        |
|                          |                                                                                                 |

Переходим к практике