

Введение в анализ данных и машинное обучение

Курс для «Дагестанского государственного технического университета»

Махачкала, 2026

Зачем ещё один курс по ML?

и для чего он вам

Базовое понимание

Разберёмся, что такое Data Science, AI, ML; какие задачи они решают, и зачем это изучать

Практические навыки

Научитесь работать с данными: анализировать, чистить, визуализировать и готовить для моделей

Реальный проект


Разработаем StreamLit-приложение с разработанными моделями — готовый проект для GitHub

Карьерная траектория

Определите, нравится ли вам эта область, прежде чем идти дальше и строить карьеру

Что мы изучим на курсе

Курс охватывает первые 3 этапа:



1. Работа с данными

Постановка задачи, типы данных, анализ и обработка данных (пропуски, выбросы)

2. Базовые модели

Линейная и логистическая регрессия, интерпретация коэффициентов

3. Оценка качества

Train/validation/test, метрики (accuracy, precision, recall, F1)



+ разработаем Streamlit-приложение для GitHub-портфолио

Структура курса: 5 занятий



Критерии зачёта

Основной критерий – формула оценки

$$0.4 * \text{степик} + 0.6 * \text{проект} + 0.1 * \text{беседа}$$

$$* \text{курс на Степик} = \frac{\% \text{ пройденного материала}}{100} * 10$$

Балл для зачета

для получения зачета нужно получить **> 6** баллов

Экзамен (ака “Беседа”)

- не понижает оценку, напротив - дает доп балл
- список вопросов заранее известен
- нужно ответить на 3 вопроса
- по желанию провести мок-собеседование (необходимо уведомить заранее)

17.10

24.10

31.10

*возможные даты

формат дз: курс на Stepik

+

финальный проект:


- Создать **Streamlit-приложение** для предсказания цены на квартиру в Дагестане
- Анализ данных → модель → деплой
- Полноценный проект в GitHub для портфолио

Вопросы



DS, AI, ML, DL – как не запутаться?

- **AI** — artificial intelligence
искусственный интеллект
- **ML** — machine learning
машинное обучение
- **DL** — deep learning
глубинное/глубокое обучение
- **DS** — data science
наука о данных



Искусственный интеллект


- системы, которые выполняют задачи, требующие «интеллектуального» поведения
- включает ML, DL, LLM, а также более ранние подходы — **системы на правилах**
- первые AI-системы часто работали по логике «если → то», заданной человеком

Пример:

Если идёт дождь → улица мокрая

Если улица мокрая → возможно, шёл дождь

Правила задаются заранее: система не обучается на данных, а делает вывод по заложенной логике




Машинное обучение

- подмножество AI: алгоритмы учатся закономерностям в данных
- типичные задачи: классификация, регрессия, рекомендации *и т.д.*
- модель получает примеры (данные) и строит прогноз для новых объектов

Пример:

- 1) подаем в модель площадь, район, этаж → обучаем →
модель предсказывает цену квартиры
- 2) подаем в модель текст письма → обучаем →
модель определяет спам или не спам




DL

Глубокое обучение

- подмножество ML: модели на основе многослойных нейронных сетей
- особенно полезно для текста, изображений, аудио и видео
- современные LLM и многие системы компьютерного зрения относятся к DL

Пример:

- 1) подаем изображения →
модель определяет, что на нём изображена кошка
- 2) современные чат-боты




DS

Data Science

- **цель** – получить полезные выводы из данных и принять на их основе решение
- работа с данными: сбор, очистка, анализ, визуализация и интерпретация
- использует статистику, теорию вероятностей *и т.д.*

Пример:

- 1) Продажи снизились на 15% → найти причину по данным
- 2) Сравнить регионы по зарплатами, построить графики и выделить ключевые факторы, влияющие на оклад



Data Science vs Machine Learning vs AI

AI —
Искусственный
интеллект

Широкая область:
любая система,
которая имитирует
интеллект

Machine Learning

Подмножество AI —
системы, которые
учатся на данных

DL

Подмножество ML —
Нейронные сети,
современные LLM

Data Science

Дисциплина, которая
использует ML и
статистику для
извлечения знаний из
данных

Транспорт → Автомобили → Гоночные автомобили

Machine Learning

наш фокус

— это часть AI, в которой мы уже не прописываем все правила вручную. Вместо этого даём алгоритму данные, и он пытается самостоятельно найти в них закономерности, после чего делает прогнозы на основе выявленных закономерностей

или

— набор всех задач, в которых компьютер может делать прогноз на основе данных

какие задачи бывают?

Как устроено машинное обучение?

Контролируемое

Неконтролируемое

Обучение
с подкреплением

Supervised Learning

Контролируемое машинное обучение — это процесс обучения модели на **размеченных** данных
(**можем** использовать значение целевого признака для обучения)

каждый столбец – **признак**
или **feature** [фича] (от англ. признак)

Кол-во комнат	Площадь, м ²	Цена, млн Р
3	109	11.3
2	72	6.7
1	52	4.5

признак, который необходимо
предсказать называется **целевым**

или **target** [таргет] (от англ. цель)
или **меткой**

каждая строка – **объект**
или **наблюдение**

Тип задачи — регрессия

Регрессия — задача, в которой модель предсказывает **числовое значение**

пример: **предсказываем цену квартиры**

известны характеристики продаваемых квартир → учимся на них

Кол-во комнат	Площадь, м²	Цена, млн ₽
3	109	11.3
2	72	6.7
1	52	4.5

Наш вопрос: какая будет цена у 2х-комнатной квартиры площадью 65 м²?

Модель отвечает на вопрос **числом**,
выдает цену

Тип задачи — классификация

Классификация — задача, в которой модель предсказывает **категорию из целевого признака (класса)**

пример: **определяем, является ли письмо спамом**

учимся на письмах, для которых уже известен правильный класс

Размер письма, кб	Есть ссылка	Класс (target)
200	да	СПАМ
32	нет	НЕ СПАМ
187	да	СПАМ

Наш вопрос: данное письмо – спам?



Модель отвечает на вопрос **классом**:

СПАМ

НЕ СПАМ

на выходе — категория / класс
классов может быть 2 и больше


Какие у вас есть идеи?

классификация

регрессия



VISAGEHALL



Какие у вас есть идеи?

классификация

регрессия

длительность
строительства

оценка риска сделки:
низкий/высокий риск




время доставки



классификация
отзывов клиента

VISAGEHALL

прогноз затрат на
производство



спрос на товар



прогноз объема
заказов




отток постоянного заказчика /
или он останется

Unsupervised Learning


Неконтролируемое машинное обучение — это процесс обучения на **неразмеченных** данных.
(**не можем** использовать значение целевого признака для обучения)

id письма	Размер	Получатели
1	8	1
2	12	1
3	43	1
4	10	2
5	40	2
6	25	5
7	23	6
8	28	6
9	26	7




Reinforcement Learning, RL

Обучение с подкреплением — это тип машинного обучения, при котором программа или робот (агент) **не получает готовых** правильных ответов, а **учится выполнять задачу** методом проб и ошибок, взаимодействуя со средой и получая награду или штраф за свои действия.



Правила:
Дойти до сундука **+100 очков**
Дойти до дракона/горы **-50 очков**



Словарь

Объект / наблюдение	Одна строка в датасете. Например, одна квартира
Признак / feature	Характеристика объекта. Например, площадь, этаж, число комнат
Целевой признак / target	Признак, который модель должна предсказать
Регрессия	Задача ML, в которой целевой признак числовой. Например, цена квартиры
Классификация	Задача ML, в которой целевой признак категориальный. Например, спам / не спам
Бинарная классификация	Классификация с двумя возможными классами, например 0/1 или да/нет
Числовые данные	Данные, значения которых являются числами и имеют количественный смысл
Категориальные данные	Данные, представляющие отдельные категории или классы, например- цвет (белый/черный) или да/нет
Кластер	Группа похожих объектов, найденная алгоритмом без заранее заданных меток

Переходим к практике