


EDA

Exploratory Data Analysis — разведочный анализ данных

Занятие 2 · Анализ реальных данных

Этапы разработки ML-проекта

EDA помогает понять данные до того, как мы начинаем усложнять модель



Сегодня остановимся здесь

EDA — Exploratory Data Analysis

Разведочный анализ данных — первичное исследование датасета, чтобы понять его структуру, качество, особенности и (возможные) закономерности

Структура данных

размер датасета · признаки · типы данных

Качество данных

пропуски · дубликаты · ошибки · выбросы

Распределения

среднее · медиана · квантили · форма
распределения

Связи признаков

корреляции · группировки · зависимости

Целевой признак

баланс классов · диапазон · утечки

Визуализация и гипотезы

графики · наблюдения · вопросы к данным

EDA в практике

01 · Найти утечку данных

Кейс №1

Цель: предсказать 0/1 — станет ли позиция НЭЗ.

Во время EDA выяснили: в одном текстовом поле категории фактически кодировали сам признак НЭЗ

→ поле исключили из обучения

02 · Качество данных

Кейс №2

На временных графиках заметили, что в данных отсутствуют отдельные периоды.

Это сразу поставило вопросы: почему возникли разрывы и как корректно восполнять периоды?

→ проблему зафиксировали и направили запрос ответственным специалистам.

03 · Генерация признаков feature engineering

Кейс №3

EDA показывает связи не только признаков с target, но и признаков между собой

Иногда отдельные признаки дают слабый сигнал, а их комбинация - сильный.

Типы данных

сначала понимаем, с каким типом признака работаем

признаки в датасете

Числовые

количество комнат
площадь · цена

дискретные / непрерывные

Категориальные

район · тип дома
класс объекта

номинальные / порядковые

Дата / время

дата объявления
время события

можно извлекать новые
признаки

Остальные

текст · bool · ID
изображения и др.

для каждого — своя логика

!!! у разных типов данных разные графики, статистики, способы обработки и проверки качества

Числовые признаки

Значения имеют количественный смысл: с ними можно выполнять арифметические операции

Дискретные

принимают отдельные счётные значения

количество комнат: 1, 2, 3, 4

- число покупок
- этаж
- количество обращений

Непрерывные

могут принимать любое значение в диапазоне

площадь: 53.2 м², цена: 8.75 млн ₽

- температура
- время доставки
- вес

Категориальные признаки

Значение обозначает группу или класс, а не количество

Номинальные

между категориями нет естественного порядка

Район: Советский, Ленинский,
Кировский

- цвет
- тип дома
- способ оплаты

Порядковые

категории можно расположить по смыслу

Состояние: плохое → среднее →
хорошее

- низкий / средний / высокий

Другие типы признаков

Иногда банан – это просто банан, но не в анализе данных

Дата / время

19.09.2026 14:30

год · месяц · день недели · сезонность

Можно разложить дату на новые признаки

Текст

«2-комн. квартира после ремонта»

длина · слова · embeddings / NLP

Смысл хранится в последовательности слов

Логические

лифт = да / нет

доля 0/1 · пропуски

Часто кодируются как bool или 0/1

ID / идентификатор

application_id = 104582

уникальность · дубликаты · качество ключа

Обычно НЕ признак для модели

- ✓ Важно про ID: число 104582 не «больше» и не «лучше» числа 104581 – это просто метка объекта
- ✓ Использовать ID как числовой признак **обычно** нельзя